

EPITECH FREE PROJECT

---

# Détection de Fraudes Bancaires

## *par Intelligence Artificielle*

---

Projet Data Science & IA | Analyse, Modélisation & Déploiement

*Document de présentation du projet*  
Année académique 2025 – 2026

# 1. Contexte et Problématique

La fraude bancaire représente l'une des menaces les plus coûteuses pour le secteur financier mondial. Selon les estimations de l'industrie, les pertes liées à la fraude par carte bancaire dépassent plusieurs milliards d'euros chaque année en Europe, affectant aussi bien les établissements bancaires que leurs clients.

Dans ce contexte, les méthodes de détection traditionnelles basées sur des règles fixes montrent leurs limites face à des schémas de fraude de plus en plus sophistiqués et évolutifs. L'intelligence artificielle, et plus précisément le machine learning, offre une réponse adaptative capable de détecter des patterns complexes dans des volumes massifs de transactions.

# 2. Présentation du Projet

|                    |                                                                 |
|--------------------|-----------------------------------------------------------------|
| Intitulé du projet | Système de Détection de Fraudes Bancaires par IA                |
| Type               | Free Project EPITECH – Data Science & Intelligence Artificielle |
| Domaine            | Fintech / Cybersécurité financière                              |
| Durée estimée      | 5 mois (planification → déploiement)                            |
| Niveau             | Bac+3 / Bac+4 – Data Analyst & Data Scientist                   |

## 2.1 Objectifs du projet

- Analyser un jeu de données de transactions bancaires réelles (ou synthétiques) et en comprendre la structure.
- Détecter les transactions frauduleuses avec une haute précision tout en minimisant les faux positifs.
- Implémenter et comparer plusieurs algorithmes de machine learning supervisés et non supervisés.
- Développer une interface de visualisation et de monitoring des alertes en temps quasi-réel.
- Documenter et présenter les résultats de façon professionnelle.

### 3. Périmètre Technique

#### 3.1 Stack technologique

| Domaine                   | Technologies                                      |
|---------------------------|---------------------------------------------------|
| Langage principal         | Python 3.10+                                      |
| Manipulation de données   | Pandas, NumPy                                     |
| Machine Learning          | Scikit-learn, XGBoost, LightGBM, Isolation Forest |
| Deep Learning (optionnel) | TensorFlow / PyTorch – Autoencoders, LSTM         |
| Visualisation             | Matplotlib, Seaborn, Plotly, Power BI / Streamlit |
| Gestion des déséquilibres | SMOTE (imbalanced-learn), class_weight            |
| Pipeline & MLOps          | MLflow, Joblib, Docker (optionnel)                |
| Base de données           | SQLite / PostgreSQL pour stockage des logs        |
| Environnement             | Jupyter Notebook, VS Code, Git / GitHub           |

#### 3.2 Source de données

Le projet utilisera principalement le dataset public Kaggle « Credit Card Fraud Detection » (284 807 transactions, 492 fraudes, features anonymisées par PCA), complété si possible par des données synthétiques générées via des outils comme SDV (Synthetic Data Vault) pour enrichir les cas de fraude.

### 4. Méthodologie & Approche

#### 4.1 Phase 1 – Exploration & Préparation des données (EDA)

- Chargement et exploration statistique du dataset (distributions, valeurs manquantes, outliers)
- Analyse du déséquilibre des classes (fraudes ≈ 0,17% des transactions)
- Visualisation des corrélations et des patterns temporels des fraudes
- Feature engineering : création de nouvelles variables pertinentes (ratios, agrégations temporelles)
- Normalisation et encodage des variables

#### 4.2 Phase 2 – Modélisation Machine Learning

- Traitement du déséquilibre : SMOTE, under-sampling, class weights
- Modèles supervisés : Logistic Regression, Random Forest, XGBoost, LightGBM
- Modèles non supervisés : Isolation Forest, Local Outlier Factor, Autoencoder
- Validation croisée stratifiée et optimisation des hyperparamètres (GridSearch, Optuna)

### 4.3 Phase 3 – Évaluation & Métriques

Dans un contexte de fraude, l'accuracy seule est trompeuse. Les métriques cibles sont :

- Precision, Recall, F1-Score (focus sur la classe minoritaire)
- AUC-ROC et AUC-PR (Precision-Recall Curve)
- Matrice de confusion et analyse des faux négatifs (fraudes non détectées)
- Coût métier simulé : pondération des erreurs par montant de transaction

### 4.4 Phase 4 – Dashboard & Déploiement

- Développement d'un dashboard interactif avec Streamlit pour visualiser les alertes
- Scoring en temps réel sur de nouvelles transactions simulées
- Export du modèle avec MLflow / Joblib
- (Optionnel) Conteneurisation avec Docker et exposition via une API REST (FastAPI)

## 5. Planning Prévisionnel

| Phase      | Période        | Livrables                                          |
|------------|----------------|----------------------------------------------------|
| Phase 1    | Semaines 1–3   | Rapport EDA, notebooks Jupyter, visualisations     |
| Phase 2    | Semaines 4–8   | Modèles entraînés, comparatif de performances      |
| Phase 3    | Semaines 9–12  | Rapport d'évaluation, courbes ROC/PR, analyse coût |
| Phase 4    | Semaines 13–17 | Dashboard Streamlit, API REST (optionnel), démo    |
| Soutenance | Semaine 18–20  | Présentation orale, rapport final, code documenté  |

## 6. Livrables

- Notebooks Jupyter commentés et reproductibles (EDA, modélisation, évaluation)
- Code source Python structuré et versionné sur GitHub (README, requirements.txt)
- Rapport technique complet (présent document enrichi des résultats)
- Dashboard interactif Streamlit déployé en local ou sur Streamlit Cloud
- Présentation orale (15-20 min + Q&A) avec slides professionnelles
- API FastAPI / Docker pour scoring en production

## 7. Compétences Mobilisées

| Compétences Techniques                                                                                                                                                                                                                                                                                                            | Compétences Transversales                                                                                                                                                                                                                                                                                                          |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <ul style="list-style-type: none"><li>Analyse exploratoire de données (EDA)</li><li>Machine Learning supervisé &amp; non supervisé</li><li>Feature engineering avancé</li><li>Gestion des données déséquilibrées</li><li>Évaluation et interprétation de modèles (SHAP)</li><li>Développement de dashboards (Streamlit)</li></ul> | <ul style="list-style-type: none"><li>Gestion de projet agile (sprints, livrables)</li><li>Communication technique et vulgarisation</li><li>Travail en équipe et versionning (Git)</li><li>Veille technologique et bibliographique</li><li>Rédaction de documentation technique</li><li>Présentation et soutenance orale</li></ul> |

## 8. Valeur Ajoutée & Perspectives

Ce projet dépasse le simple exercice académique en adressant un problème métier concret et à fort enjeu économique. La construction d'un pipeline complet — de la donnée brute au modèle déployé — simule les conditions réelles d'un projet data en entreprise.

Les perspectives d'extension incluent la mise en place d'un système d'apprentissage continu (online learning) pour adapter le modèle à l'évolution des schémas de fraude, l'intégration de données textuelles (NLP sur les libellés de transactions), et l'exploration de techniques de federated learning pour respecter la confidentialité des données bancaires.

Ce projet constitue un atout solide pour un portfolio Data Analyst / Data Scientist, démontrant la maîtrise de l'ensemble du cycle de vie d'un projet ML en production.

## 9. Références & Ressources

- Dataset : Kaggle – Credit Card Fraud Detection (ULB Machine Learning Group)
- Dal Pozzolo et al. (2015) – Calibrating Probability with Undersampling for Unbalanced Classification
- Documentation Scikit-learn, XGBoost, LightGBM, imbalanced-learn
- Streamlit Documentation – streamlit.io
- MLflow Documentation – mlflow.org
- SHAP (SHapley Additive exPlanations) – shap.readthedocs.io